MP2 课程报告：基于一致性与表征的 LLM 候选答案选择

课程： DASE7506 Advanced Machine Learning Methods · Fall 2026
作业： MP2 — Selecting Reliable LLM Reasoning
协议： `dase7506-mp2-open-hard-verifier-v5`
作者： BORUI HAN（学号：3036781090）
代码与检查点： https://github.com/HBrEwba/DASE7506-MP2 （`main`） / `code/runs/model_bundle`
日期： 2026-10-22

---

1. 任务与问题设定

给定一道小学数学应用题（源自 GSM8K）及同一问题的 **4 条 LLM 候选推理轨迹**，方法需输出一个整数索引 $i\in\{0,1,2,3\}$。官方评分器仅用 `common.parse_answer` 核对所选候选的**最终数值答案**是否与参考答案等价（支持分数/小数等价），**不**评价推理过程是否步步正确。

数据划分：训练集 4755、验证集 798、测试集 467；互不重叠。每组至少有一个最终答案正确的候选；测试集刻意更难（每组至少存在两种不同的可解析答案）。输入还包括冻结的整段轨迹嵌入 `embeddings`，形状 $[N,4,1024]$。

约束要点：仅用训练集拟合；验证集做开发与选型；测试参考不得用于训练/调参/查表；推理资产 ≤16 MiB；完整 CPU 评测（4 线程）≤30 s；禁止评测期调用 LLM API 或外挂预训练权重。

本报告关注的研究问题：

1. **候选间一致性（多数票）能走多远？** 在何种难度上会系统性失效？
2. **冻结嵌入是否提供多数票之外的可分信号？** 用训练内 PCA 投影后，线性排序能否显著超过一致性基线？
3. **强多数（maj3）是否应硬门控？** 在弱/强表征模型下结论是否一致？

---

2. 方法

2.1 基线：解析答案多数票

对每条候选调用 `parse_answer`。若存在**唯一众数**，选该答案对应的第一个候选；否则选与四个嵌入均值 L2 最近的候选。该基线训练无关，验证集 **85.46%**。

失败结构（验证集 116 错）：唯一错误众数 60、平票/回退失败 56。其中 **maj3（三人同答）** 约 96% 可靠，**maj2** 约 71%；平票时纯嵌入最近邻较弱。Oracle（四人中至少一人正确）为 100%，说明上限在“识别”而非“生成”。

2.2 最终方法：训练内 PCA + 列表 Softmax 线性打分

特征（每候选 339 维）：

1. **17 维手工特征**：是否可解析、答案同意比例、是否唯一众数成员 / 并列顶端 / 单例答案、众数强度、到均值嵌入的 −L2、与均值余弦、与其它候选的均/最大成对余弦、长度与问题词重叠、以及 mode×cos、agreement×cos、minority×cos 交互项。
2. **全局 PCA**：对训练集全部候选嵌入拟合 PCA，方差阈值 **0.9** → $k=161$（k 仅由训练方差决定，不在验证集上搜）。特征为 $(\mathbf{e}-\boldsymbol{\mu}_{\mathrm{pca}})W$。
3. **局部 PCA**：同一组 W 作用于题内残差 $(\mathbf{e}-\bar{\mathbf{e}})W$，刻画相对几何。

模型： 列表 softmax 交叉熵（题内正确候选上均匀目标），余弦退火 SGD，lr=0.05，epochs=300，L2=1e-4，seed=42；特征用训练集均值/方差标准化。在**全部训练题**上拟合（非仅 hard 子集）。

推断： 对四候选打分后 `argmax`。**不再使用 maj3 硬门控**（见消融：在 PCA 表征下，打分器单独优于 gate3）。

资产： `runs/model_bundle/{scorer.npz,meta.json}`，PCA 存 float32，合计约 **0.60 MiB**（≪16 MiB）。依赖仅 `numpy==2.5.3`。

2.3 曾尝试但未采用的改进（验证集未超过 91.23%）

在冻结当前最优之后，又针对剩余约 70 个验证错误做了一轮探索，**均未超过 91.2281%**，故**保留原检查点，未用测试集重调**：

尝试	验证集结论
小 MLP（32–128 hidden）及 dropout/L2 变体	最好约 90.98%，低于线性
不确定时回退多数票（margin 阈值）	净伤害（fix≪break）
maj3 几何规则（单例更靠近均值则翻转等）	≤91.23%，或明显下降
hard 子集残差 MLP 混合	随 α 单调变差
多种子分数平均、pairwise+listwise、熵特征	持平或略差

结论：在当前特征下，**线性列表模型已较充分**；剩余错误更像标签/表征不可分，而非欠拟合。

---

3. 实验与消融

评测命令与官方一致：`predict.py` + `score_predictions.py`。方法选型**只看验证集**；测试集在冻结后**只跑一次**。

3.1 主结果

划分	多数票基线	v1（hard 线性+gate3，无 PCA）	**最终方法 v2**
Validation	85.4637%（682/798）	87.4687%（698/798）	**91.2281%（728/798）**
Test	69.3790%（324/467）	72.5910%（339/467）	**79.4433%（371/467）**

测试集更难（多样可解析答案），绝对精度低于验证集符合数据构造；相对基线仍有约 **+10.1 pp**（test）与 **+5.8 pp**（val）。

3.2 消融（验证集）

变体	Val Acc
多数票 + 嵌入回退	85.46%
仅 17 维手工特征 + 列表线性（train-all，无门控）	87.09%
v1：hard-only 线性 + maj3 门控（无 PCA）	87.47%
PCA（k=161）+ 列表线性 + maj3 门控	90.48%
PCA + 列表线性 + 无门控（最终）	**91.23%**
PCA + 额外“富特征”（答案是否出现在题面、数字支持度等）	90.98%（略差）

要点：

- **PCA 是主要增益来源**（约 +4 pp 相对无 PCA 线性）。
- 在强 PCA 打分器下，**去掉 maj3 门控更好**：打分器可纠正部分错误 maj3，且不显著破坏简单题。

- 额外启发式文本特征未带来稳定收益，故最终配置保持简洁的 17 维 + PCA。

3.3 资源

项目	数值
推理资产（未压缩合计）	≈ 0.60 MiB
本地预测耗时（validation / test，4 线程）	≈ 0.31 s / 0.21 s
训练	CPU，NumPy 纯实现，分钟级
随机种子	42（五种子验证波动极小）

远低于 16 MiB / 30 s 约束。

---

4. 误差分析

最终方法验证集错 **70** 题，粗分：平票相关约 31、maj2 约 23、maj3 约 16。

例 1（平票）： Megan 买蛋题。解析答案 `['9','18','6',None]`，金标 `9`，模型选 `6`。四人无一致众数，需完全依赖表征/长度等弱线索。

例 2（maj2）： Grace 南瓜派题。解析 `['6','4','2','4']`，金标 `4`（出现两次），模型选 `6`。弱多数本身不可靠，打分器仍可能偏好错误单例。

例 3（maj3 羊群错误）： Yun 回形针题。解析 `['9','17','17','17']`，金标 `9`。三人同错形成强先验；嵌入上正确单例常呈“离群”，与“正确答案更居中”的多数正确题模式相反，几何启发式容易两头不讨好。

整体观察：评分只看最终数字，模型学到的主要是**答案一致性结构 + 轨迹嵌入几何**，而非逐步验算。因此“推理看起来对但算错”与“推理跳跃但答案对”在监督信号上不可分。

---

5. 局限与后续

1. **不验证算术步骤**：轻量数字一致性特征在剩余错误上增益有限，完整符号执行超出本作业资产/时间设定。
2. **错误 maj3 仍难**：与三人同错绑定时，监督与几何信号都弱。
3. **验证/测试难度差**：测试构造含多样答案，泛化需审计集进一步确认。
4. **未使用外部知识/更大模型**：符合课程约束，但也限制了上限。

可能的后续（未实施）：题型分层、更结构化的中间量抽取、或在资产允许下的极浅交互网络——但本轮 MLP 未超过线性，需谨慎。

---

6. 复现要点

```bash
cd code
python -m venv .venv && source .venv/bin/activate
python -m pip install -r requirements.txt
python check_data.py
python train.py --output runs/model_bundle --seed 42 --pca-var 0.9 --majority-gate 0
OMP_NUM_THREADS=4 OPENBLAS_NUM_THREADS=4 MKL_NUM_THREADS=4 \
```

```
python predict.py --method submission.py --checkpoint runs/model_bundle \
  --split test --output runs/test-predictions.json
python score_predictions.py --split test \
  --predictions runs/test-predictions.json --output runs/test-score.json
```

同伴复现可直接使用提交的 `runs/model_bundle`，无需重训。详细笔记见 `code/runs/NOTES.md`。

---

7. AI 使用与复用声明（占位，提交前请核对）

- **AI 辅助：** 使用 AI 编程助手参与代码实现、实验脚本与报告初稿整理；方法设计（多数票门控、训练内 PCA、列表 softmax、消融决策）由作者理解并负责。作者已阅读并能够解释全部提交代码与训练流程。
- **复用：** 数据与评测来自课程仓库 DASE7506-MP2（GSM8K / Qwen3-0.6B 候选与嵌入，见 `data/LICENSE.txt`、`NOTICE.txt`）。未使用外部数据集或额外预训练权重。
- **声明签字：** BORUI HAN / 3036781090 / 2026-10-22

---

8. 提交清单（作者待办）

- [x] 填写学号与姓名
- [x] 将代码与 `runs/model_bundle` 推送到**公开** GitHub 仓库（https://github.com/HBrEwba/DASE7506-MP2）
- [ ] 将本报告导出为 ≤10 页 PDF（可删减第 2.3 节细节表）
- [ ] 在 [MP2 网站](https://xudongwu-0.github.io/courses/dase7506/mp2/) 提交：**学号、官方 scorer 的 test accuracy（79.4433）、代码链接、检查点链接**
- [ ] 按网站流程创建 GitHub issue 完成最终提交（仅生成链接不等于提交）
- [ ] 截止：**2026-10-31 23:59（北京时间）**

附录：关键文件路径

路径	说明
`code/submission.py`	推断接口
`code/features.py` / `code/train.py`	特征与训练
`code/runs/model_bundle/`	推理资产
`code/runs/validation-score.json`	验证官方分数
`code/runs/test-score.json`	测试官方分数（冻结后一次）
`code/runs/NOTES.md`	英文实验笔记